

신용카드 사기 거래 탐지

5(1) Basic ML 과제 분석 리포트

1. 데이터

원본 creditcard.csv는 284,807건, 31개 컬럼이다. 사기 거래(Class=1)는 492건으로 전체의 0.173%에 불과한 극단적 불균형 데이터다. 연산량을 줄이기 위해 사기 거래는 전부 유지하고 정상 거래는 10,000건만 무작위 추출해 총 10,492건의 샘플을 구성했다. 샘플 내 사기 비율은 4.69%다.

2. 전처리

Amount 컬럼의 스케일이 다른 피처(PCA 결과인 V1~V28)와 크게 달라 표준화했다. 이때 데이터 누수를 막기 위해 분할을 먼저 수행했다. StandardScaler를 학습셋에만 fit하고 테스트셋에는 그 통계량으로 transform만 적용했다. 8:2 분할에 stratify를 적용해 학습 8,393건, 테스트 2,099건으로 나뉘고 양쪽 모두 사기 비율이 약 4.7%로 유지됐다.

3. 불균형 처리 및 모델

학습셋에만 SMOTE를 적용해 사기 거래를 394건에서 7,999건으로 늘려 1:1 균형을 맞췄다. 테스트셋은 실제 분포를 평가해야 하므로 그대로 두었다. 모델은 RandomForestClassifier(random_state=42)를 기본 설정으로 사용했다.

4. 성능

클래스	Precision	Recall	F1-score	Support
0 (정상)	0.9945	0.9975	0.9960	2,001
1 (사기)	0.9457	0.8878	0.9158	98

PR-AUC (Average Precision): 0.9538

혼동행렬 기준 실제 사기 98건 중 87건을 탐지했고, 정상 거래를 사기로 잘못 분류한 건수는 5건이다.

5. 결론

목표치는 Recall 0.80 이상, F1 0.88 이상, PR-AUC 0.90 이상이었다. 사기 클래스 기준 Recall 0.8878, F1 0.9158, PR-AUC 0.9538로 세 지표 모두 목표를 넘겼다. 가장 빠듯한 항목은 Recall이지만 목표 대비 약 0.09의 여유가 있다.

threshold는 predict()의 기본값인 0.5를 그대로 사용했고 별도의 임계값 조정이나 하이퍼파라미터 탐색은 하지 않았다. RandomForest와 SMOTE 조합만으로 목표를 달성했기 때문이다. Recall을 더 높이려면 threshold를 낮출 수 있으나 그만큼 Precision이 떨어지는 교환 관계가 있다.